Laboration 1: Deskriptiv statistik

Statistisk analys

Emil Erikson och August Jonasson*

HT 25

Viktigt: Innan ni läser vidare

Gör först följande:

1. (Om ni inte gjort det tidigare) I den övre menyn i `RStudio`, tryck på `Tools -> Global Options -> Code -> Saving`. Under "Default text encoding", tryck på "Change" och välj "UTF-8".
2. Gå in på kurshemsidan och ladda ner mallen för denna laboration. Öppna den i `RStudio`. Skriv er rapport i denna fil.

Krav för laboration 1

Tänk på följande **krav** på er rapport:

- Rapporten måste kunna läsas av någon som inte har läst labbinstruktionerna. Så ni måste skriva vad det är ni ska göra innan ni gör det, och berätta vad syftet är.
- Rapporten måste vara skriven i `R Markdown`.
- All kod som används måste synas i labbrapporten, men ska inte beskrivas i detalj i rapporten.
- Alla **tabeller och diagram** måste förses med **numrering och beskrivande text**, och refereras till i rapportens vanliga text på rätt sätt. Diagram måste ha lämpliga rubriker på axlarna och tabeller lämpliga rubriker på kolumner.

*Tidigare versioner av Leo Levenius, Erik Thorsén, Benjamin Allévius och Fredrik Olsson.

Denna laboration

Denna första datorlaboration i kursen **Statistisk analys** består väsentligen av tre olika delar:

1. En introduktion (eller minnesuppfräschning) till `R`, som kommer att användas på samtliga laborationer.
2. En övning i att avgöra huruvida ett stickprov kan anses normalfördelat.
3. En deskriptiv (beskrivande) analys av ett litet datamaterial.

Som förberedelse till laborationen ska den teoretiska Uppgift 1 lösas. Uppgift 2 och 3 skall redovisas skriftligt senast det datum som anges på schemat.

Introduktion till Deskriptiv statistik

I kursen Sannolikhetsteori I fick ni en introduktion till `R`. Alla dokument som användes i denna introduktion finns att hitta även på hemsidan för denna kurs, så ni kan kika i dem för att fräscha upp minnet. Här ska vi istället kika på vad `R` har att erbjuda när det kommer till att beskriva datamängder. För att få en uppfattning om hur ni kan beskriva ett datamaterial numeriskt och grafiskt ska ni genomföra följande enkla uppgift.

I staden Grötköping mättes kroppslängden på 11 av stadens invånare och resultaten (i cm) blev

```
 [1] 174.6 173.2 189.6 167.7 179.2 179.6 170.5 168.5 185.3 164.1 178.4
```

Börja med att mata in data i variabeln `x`. De vanliga läges- och spridningsmåtten kan enkelt fås med hjälp av funktionerna `mean` (för medelvärdet), `var` (för stickprovsvariansen), `sd` (för stickprovsstandardavvikelsen), och `summary` (för minimum, maximum, median och kvartiler).

Ett träd-bladdiagram fås med `stem`, histogram med `hist`, boxplot med `boxplot`, och normalfördelningsplot med `qqnorm`. I samtliga fall räcker det att ange vektorn `x` som enda argument så ritar `R` upp diagrammet automatiskt. Dock vill vi att ni sätter passande rubriker på axlarna när ni skapar diagram—för att se hur ni gör det, titta på hjälpsidan för plotfunktionen, t.ex. genom att skriva `?hist` i `Console` i `RStudio`. För att skapa figurrubrik använd `fig.cap`.

När det gäller histogram kommer ni ibland vilja ha en annan klassindelning än den som `R` ger automatiskt. Pröva exempelvis

```
hist(x, breaks = seq(from = 162, to = 192, by = 5))
```

och

```
hist(x, breaks = seq(from = 162, to = 190, by = 4))
```

och se vad som händer. Här ser vi att vi anger brytpunkterna (argumentet `breaks`) för histogrammet genom att specificera en vektor som i det andra fallet är en talsekvens med 162 som första värde, 190 som sista värde, och med tal däremellan som har avståndet 4 till talen strax före och efter.

När det gäller normalfördelningsplotten så är den konstruerad på ett sådant sätt att data kommer att ligga längs en rät linje om data verkligen är normalfördelade. En sådan jämförelse underlättas om ni ritar ut en rät linje, vilket enkelt kan åstadkommas med kommandot `qqline(x)`. Dvs, ni skriver

```
qqnorm(x)
qqline(x)
```

Uppgift 1: Två teorifrågor (behöver ej redovisas skriftligt)

1. Den stokatiska variabeln Z är likformigt fördelad med väntevärde a. Vad ska fördelningens övre och undre gränser vara, uttryckt i a, för att standardavvikelsen ska bli lika stor som väntevärdet? Ledning: Om $Z \sim \mathrm{U}[\alpha, \beta]$, så gäller att $\mathrm{Var}(Z) = (\beta - \alpha)^2/12$.
2. Den stokastiska variabeln X är t-fördelad (mer om denna fördelning i nästa uppgift) med 4 frihetsgrader - skrivs $X \sim t_4$ eller $X \sim t(4)$. Då gäller att $\mathrm{E}[X] = 0$ och $\mathrm{Var}(X) = 2$. Beräkna väntevärde och standardavvikelse för variabeln $Y = \frac{a}{\sqrt{2}}X + a$.

Notera: beteckningen $\mathrm{U}[\alpha, \beta]$ är ekvivalent med beteckningen $\mathrm{Re}[\alpha, \beta]$ eller $\mathrm{Re}(\alpha, \beta)$ ni har stött på tidigare. Den likformiga fördelningen kallas "the uniform distribution" på engelska, därav U:et. Ibland ser man också $\mathrm{Uniform}(\alpha, \beta)$ eller $\mathrm{Uniform}[\alpha, \beta]$.

Uppgift 2: Är datan normalfördelad?

När ni i framtiden kommer att syssla med praktiska tillämpningar av matematisk statistik kommer ni troligtvis ställas inför frågan om en uppsättning data kan anses komma från en normalfördelning (eventuellt med viss approximation). I det fallet har ni således (eller förhoppningsvis) ett stickprov med n oberoende observationer från en okänd sannolikhetsfördelning. Frågan är om den okända fördelningen kan vara en normalfördelning.

Vi ska här jämföra olika grafiska metoder som kan användas för att besvara ovanstående fråga. Vi ska också försöka svara på frågan om hur stort n behöver vara för att vi med rimlig approximation ska kunna avgöra om data är normalfördelade eller inte. För detta ändamål ska vi simulera data från för oss kända fördelningar, både normalfördelade och icke-normalfördelade. Alla fördelningar som ni ska jämföra ska ha väntevärde och standardavvikelse lika med a, där a är vilken dag i månaden du är född (om ni jobbar i par, välj den enas dag att jobba med).

Uppgift 2.1: Simulera och plotta data

Vi ska börja med att simulera data från tre olika fördelningar - normal, t-fördelad, och likformig - med tre olika stickprovsstorlekar: $n = 20$, $n = 80$, och $n = 320$. För varje kombination av fördelning och stickprovsstorlek ska vi sedan plotta histogram, boxplot och normalfördelningsplot (även kallat Q-Q plot). Totalt blir det alltså 27 plottar.

Simulera från respektive fördelning

Normalfördelad data kan enkelt simuleras i `R` med funktionen `rnorm(n, m, s)`, där `n` anger antal värden som skall simuleras, `m` anger väntevärde, och `s` anger standardavvikelse för normalfördelningen som skall simuleras från. För att säkerställa reproducerbarhet av resultaten vill vi även använda oss av funktionen `set.seed` i början av kodblocket där slumpdragningen sker.

```
a <- 20 # fyll i vilken dag i månaden du är född. Om ni jobbar i par, välj den enas.

set.seed(19690420) # fyll i ditt egna födelsedatum. Om ni jobbar i par, välj den enas.
n1 <- rnorm(20, a, a)
n2 <- rnorm(80, a, a)
n3 <- rnorm(320, a, a)
```

Vill vi inspektera ett stickprov kan vi använda oss av `print`-funktionen, alternativt bara skriva vektorn vi är intresserade av i konsolen och sedan trycka på enter.

```
print(n1)
```

```
##  [1] -19.8023560  37.6116907  30.5721382   3.2557321  10.2726972   7.1497468
##  [7]  15.3221109  27.9802257  -6.1835835  29.9758195  15.2567691  22.8897066
## [13]  39.3552946  30.4258810 -20.2540409  19.5677455  51.1330301  21.9194498
## [19]  33.9188574   0.6605108
```

För simulering av likformigt fördelade stickprov används i `R` funktionen `runif(n, min, max)`, där `n` anger stickprovsstorleken och `min` och `max` anger undre respektive övre gräns i det intervall som fördelningen är definierad för. Lösningen på Uppgift 1 ger er intervallgränserna för det värde på a som ni använder. Byt ut "..." nedan mot dessa.

```
lower <- ... # lägre gräns för den likformiga fördelningen
upper <- ... # övre gräns för den likformiga fördelningen

set.seed(19690420) # fyll i ditt egna födelsedatum. Om ni jobbar i par, välj den enas.
u1 <- runif(20, lower, upper)
u2 <- runif(80, lower, upper)
u3 <- runif(320, lower, upper)
```

Slutligen vill vi simulera data från t-fördelningen som, likt standard normalfördelningen, är en symmetrisk, centrerad och "klockformad" fördelning som ofta dyker upp i statistiska sammanhang. Skillnaden gentemot normalfördelningen är att t-fördelningen har tjockare svansar, vilket kontrolleras av antalet frihetsgrader. Ju lägre antal frihetsgrader, desto mer sannolikhetsmassa ute i svansarna, och låter vi antalet frihetsgrader gå mot oändligheten så blir faktiskt t-fördelningen precis en standard normalfördelning. Således kan det vara rätt svårt att urskilja, från en plottad täthet exempelvis, om en variabel är t-fördelad eller normalfördelad. Därför utgör t-fördelningen ett bra exempel för oss att studera här.

För simulering av t-fördelad data i `R` används funktionen `rt(n, df)`, där n är stickprovsstorleken och df är antalet frihetsgrader (degrees of freedom), vilket vi låter fixeras till 4. Applicera lämplig transformation på stickproven nedan, sådan att väntevärde och standardavvikelse blir a:

```
set.seed(19690420) # fyll i ditt egna födelsedatum. Om ni jobbar i par, välj den enas.
t1 <- ... rt(20, 4) ... # byt ut (...) mot lämplig transformation
t2 <- ... rt(80, 4) ...
t3 <- ... rt(320, 4) ...
```

För att kontrollera att transformationen applicerats korrekt kan man exempelvis simulera ett större stickprov från t-fördelningen, applicera sin transformation, och sedan använda funktionerna `mean()` och `sd()` för att se om väntevärde och standardavvikelse verkar närma sig a. Kör följande kodblock några gånger (utan seed) för att se (behöver ej vara med i rapport).

```
test <- ... rt(10**4, 4) ... # byt ut (...) mot lämplig transformation
mean(test)
sd(test)
```

Plotta data för respektive fördelning och stickprovsstorlek

Vi ska nu ta fram histogram, boxplottar och normalfördelningsplottar för den simulerade datan. Eftersom vi ska titta på så många plottar kan det vara lämpligt att försöka samla flera av dem i ett och samma fönster. För detta kan funktionen `par` användas i `R`. I följande kodexempel samlar vi alla histogram och normalfördelningsplottar för den normalfördelade datan i ett och samma fönster.

```
old_par <- par(mfrow = c(2,3)) # 2 rader, 3 kolonner
hist(n1)
hist(n2)
hist(n3)
qqnorm(n1)
qqline(n1)
qqnorm(n2)
qqline(n2)
qqnorm(n3)
qqline(n3)
par(old_par) # säg åt R att sluta förvänta sig fler plottar till samma fönster
```

Boxplottar kan å andra sidan fördelaktigt samlas i en och samma plot på en gång.

```
boxplot(n1, n2, n3)
```

Bestäm själva hur ni vill presentera era plottar men se till så att alla 27 plottar är med, att de är läsbara samt att **Krav för laboration 1** är uppfyllda. I nästa uppgift kommer ni behöva kunna hänvisa till dessa plottar.

Uppgift 2.2: Frågor

Svara på nedanstående frågor i löpande text och inte i listform. Era svar ska vara motiverade och ge tydliga hänvisningar till de relevanta figurerna, fördelningarna och stickprovsstorlekerna i föregående uppgift.

1. Vilket sorts diagram tycker du beskriver respektive fördelning bäst?
2. För respektive fördelning, vilket är det minsta n för respektive typ av plot så att det går att urskilja om datan är normal eller inte? (I fallet icke-normal räcker det med att konstatera att den **inte är normal**, det behöver ej synas vilken fördelning det är) Går det för alla fördelningar och plottar? Vilken plot är bäst överlag?

Uppgift 3: Explorativ dataanalys

Ni ska nu undersöka ett verkligt datamaterial med de grafiska metoderna ovan samt med så kallade scatterplots (spridningsdiagram) som illustrerar beroenden mellan variabler på ett bra sätt. Ett spridningsdiagram är helt enkelt det ni får genom att skriva

```
plot(x, y)
```

och som ni vet från kursen Sannolikhetsteori I så kan ni ge fler argument till denna funktion för att göra plotten snyggare. **Kom till exempel ihåg att ni måste ange passande rubriker på axlarna, och glöm absolut inte att numrera diagrammet och att ge det en beskrivande text!** *Tips*: Använd `fig.cap` för automatisk numrering.

På kursens hemsida finns filen `olvinsprit.csv` som innehåller data över genomsnittlig konsumtion av öl, vin och starksprit i några OECD-länder. Börja med att spara filen i **samma mapp** som ni placerat er `.Rmd`-fil för labbrapporten i, exempelvis `Documents/Kurser/statan1/Labb1` eller liknande. Se till att filen sparas som en `.csv`-fil och inget annat (som t.ex. `.php`). För att vara övertydlig: spara filen som `olvinsprit.csv`. Vi kan därefter läsa in den i `R` genom

```
data <- read.csv("olvinsprit.csv", header = TRUE)
```

Skapa därefter de fyra variablerna

```
land <- data$Land
beer <- data$beer
vin <- data$vin
sprit <- data$sprit
```

Nu kan vi rita en scatterplot med kommandot

```
plot(beer, vin) # När ni gör detta själv, ange passande axelrubriker etc
```

vilket i det här fallet ger ölkonsumtionen och vinkonsumtionen för samtliga länder. Vill ni tydligare se vilka länder punkterna motsvarar skriver ni

```
plot(beer, vin) # När ni gör detta själv, ange passande axelrubriker etc
text(beer, vin, land)
```

så dyker namnen på länderna upp istället för punkterna. Skapa sådana här plottar för respektive par av variabler (tre totalt).

Frågor uppgift 3

Illustrera nu fördelningen för de tre variablerna var för sig. Uppgift 3 ska redovisas skriftligt. Svara på följande frågor **i löpande text, inte i punktform**.

1. Vilka alkoholtyper i `olvinsprit.csv` kan anses komma från en normalfördelning?
2. Hur ligger Sverige till i förhållande till andra länder inom de olika alkoholtyperna? Är Sverige extremt åt något håll?
3. Vilka länder kan anses extrema? Åt vilket håll är de extrema?
4. Finns det gemensamma drag hos de extrema länderna?
5. Medför hög konsumtion av en typ av alkohol en högre eller lägre konsumtion av de andra typerna? Påverkar de varandra alls?
6. Sammanfatta era slutsatser om alkoholkonsumtionen i OECD-länderna.

- Kom ihåg att **numrera och ge en beskrivande text** till **alla** diagram. *Tips*: Använd `fig.cap` för automatisk numrering.